

Medindo a Capacidade dos Modelos de Linguagem de Navegarem em Espaços Representados em Formato 2D Textual

Pablo A. Sampaio

Abstract

Este é o resumo do artigo. Ele apresenta brevemente o problema, a abordagem proposta, os principais resultados e as conclusões.

1 Introduction

O sucesso recente dos *grandes modelos de linguagem* (LLMs) baseados em *redes transformers autorregressivas* veio da sua adoção como motores cognitivos para realização de tarefas diversas, variando entre tarefas ligadas ao processamento textual direto (conversar, traduzir, informar, resumir textos) até tarefas que onde o modelo é usado em múltiplos passos, tais como: realização buscas profundas na web, realização de pesquisa científica, ou desenvolver código (Zhao et al. 2026). As crescentes expectativas levaram ao rápido avanço na área, com lançamento de novos modelos, criação de variações arquiteturais e novos regimes de treinamento. Porém, para uma comparação adequada e para avaliar o progresso que os novos modelos representam, é preciso avaliá-los. Para isso, são aplicados diversos *benchmarks* (existentes antes ou novos).

Em alguns desses benchmarks, o modelo de linguagem é avaliado com base na sua capacidade de gerar uma saída correta em apenas uma etapa. Tipicamente, tais benchmarks são baseados em um dataset de onde são obtidas as entradas que são fornecidas ao modelo. A saída gerada pelo modelo é, então, avaliada, seja pela simples comparação com uma resposta de referência ou por algum método programático. Por exemplo, o **MMLU** (*Massive Multitask Language Understanding*) avalia o conhecimento e a capacidade de resolução de problemas de modelos de linguagem em 57 disciplinas por meio de questões de múltipla escolha (Hendrycks et al. 2020). O **GSM8K** (*Grade School Math 8K*), por sua vez, avalia a capacidade de resolver problemas matemáticos, usando um dataset de perguntas textuais com respostas conhecidas (Cobbe et al. 2021). O **HumanEval** fornece problemas de programação para os quais o código gerado como saída do modelo é avaliado por testes funcionais (Chen et al. 2021).

Resumo legal: Em alguns benchmarks tradicionais, o modelo recebe uma entrada e sua resposta é avaliada diretamente segundo um gabarito ou critério de correção predefinido. Exemplos incluem o *MMLU*, que avalia questões de múltipla escolha em 57 disciplinas (Hendrycks et al. 2020), o *GSM8K*, voltado à resolução de problemas matemáticos (Cobbe et al. 2021), e o *HumanEval*, que avalia código gerado por meio de testes funcionais (Chen et al. 2021)."

Outros benchmarks avaliam a capacidade de usar o modelo em tarefas que requerem *múltiplas* etapas de geração de saída. Nestes, o modelo é tipicamente testado acoplado a uma camada de

software adicional ¹ previamente definida, que usa o modelo para a realização da tarefa em um processo que repete: observar (receber uma entrada que representa) o estado da tarefa, tomar uma decisão (realizar de ação) capaz de afetar o estado da tarefa. Juntos, o LLM e essa camada podem ser conceituados como um *agente inteligente* [Russell et al. (1995)](Shoham and Leyton-Brown 2009). Tarefas como as citadas serão chamadas de *tarefas agênticas* e benchmarks que avaliam alguma habilidade de um agente baseado em LLM são chamados *benchmarks agênticos*, neste trabalho.

Note que cada *benchmark* mede a capacidade do modelo em um aspecto ou em um tipo de tarefa em particular. Esse trabalho é baseado na crença de que novos *benchmarks* ainda precisam surgir para medir o modelo sobre diferentes aspectos.

Diante disso, estamos propondo... usar o minigrid, trocando a representação para 2D avaliar os resultados para diferentes providers (pegandos os modelos mais importantes) para diferentes modelos de uma mesma família (variando o tamanho) entre famílias (considerando um tamanho fixo de modelo)

1.1 Problem Statement

Veja Figure 1.



Figure 1: 1907 Franklin Model D roadster. Photograph by Harris & Ewing, Inc. [Public domain], via Wikimedia Commons. (<https://goo.gl/VLCRBB>).

¹Atualmente, esta camada tem sido chamada de *harness* do agente. Porém, podemos considerar que o software é o *próprio* agente, e que o modelo é usado como um módulo dele.

1.2 Contributions

As principais contribuições deste trabalho são:

- primeira contribuição;
- segunda contribuição;
- terceira contribuição.

2 Related Work

Ver (Xi et al. 2025) e (Acharya et al. 2025)

Sobre mecanismos de tomada decisão, pode ser útil (decidir): <https://jasss.soc.surrey.ac.uk/17/4/13.html> (2014)

Falar que permite medir avanços - O uso de bench é uma prática bem estabelecida - times usam os benchmarks ao lancar os modelos, e.g. (Achiam et al. 2023) (Team et al. 2026)

Críticas gerais: - (McIntosh et al. 2025)

- críticas e recomendações: https://proceedings.neurips.cc/paper_files/paper/2025/hash/1967e0fc3aa6cb-bace562f5cb8e3954e-Abstract-Datasets_and_Benchmarks_Track.html
- críticas e recomendações: <https://aclanthology.org/2024.emnlp-main.764/>
- pode ter ideias interessantes: <https://arxiv.org/abs/2601.03986>
- falar de test contamination que atrapalha os avanços e cria uma necessidade de novos https://proceedings.iclr.cc/paper_files/paper/2025/hash/e4a46394ba5378b3f9a186a5b4c650d1-Abstract-Conference.html > Test set contamination, wherein test data from a benchmark ends up in a newer model’s training set, is a well-documented obstacle for fair LLM evaluation and can quickly render benchmarks obsolete. To mitigate this, many recent benchmarks crowdsource new prompts and evaluations from human or LLM judges; howev

Dar detalhes dos benchmarks agênticos que existem.

À medida que surgem agentes para fazer pesquisa de ML (Lu et al. 2026) – artigo da Nature –, surgem benchmarks MLE-bench (Chan et al. 2025)

Outros benchmarks, como o **GLUE**, agregam uma coleção de datasets, que representam tarefas de compreensão de linguagem natural com suas respostas; cada dataset tem um métrica própria de avaliação (Wang et al. 2018).

Benchmarks agênticos (para ver os nomes e identificar se tem algum similar): <https://benchlm.ai/benchmarks>

Escolher uns 5 recentes, dos mais citados.

BALROG (Paglieri et al. 2025) https://proceedings.iclr.cc/paper_files/paper/2025/file/f0b1515be276f6ba82b4f21-Paper-Conference.pdf um benchmark para avaliar capacidades agênticas de LLMs e VLMs em tarefas de longo horizonte temporal. Os autores argumentam que benchmarks existentes normalmente envolvem poucas interações (como navegação na web ou uso de ferramentas), sendo insuficientes para avaliar habilidades como planejamento de longo prazo, raciocínio espacial,

exploração e adaptação em ambientes dinâmicos. Eu diria que este é um dos artigos mais relevantes para a sua revisão. Diferentemente de benchmarks voltados para uso de ferramentas (como AgentBench, WebArena ou -Bench), o BALROG tem como foco explícito a avaliação de capacidades cognitivas de agentes em ambientes interativos, incluindo planejamento, raciocínio espacial, exploração, atribuição de crédito, descoberta da dinâmica do ambiente e tomada de decisão sequencial. A principal diferença para o seu benchmark é que o BALROG agrega vários ambientes já existentes, enquanto o seu trabalho propõe um ambiente textual próprio, representando um mundo 2D descrito apenas por texto, especificamente para avaliar esse tipo de tomada de decisão.

How Well Do Agentic Skills Work in the Wild: Benchmarking LLM Skill Usage in Realistic Settings (Liu et al. 2026) <https://arxiv.org/abs/2604.04323> ler e resumir ele faz algo que é bastante complementar ao meu trabalho: ele investiga como o uso de “skills” (memórias procedurais reutilizáveis) afeta o desempenho de agentes baseados em LLM em benchmarks agênticos, e argumenta que avaliações anteriores são excessivamente otimistas por utilizarem condições irreais. Para o contexto do seu artigo, eu destacaria principalmente a discussão metodológica sobre como construir benchmarks agênticos mais realistas, pois ela dialoga diretamente com a motivação do seu benchmark.

Pesquisa no scispace: <https://scispace.com/chat/83a8e6e9-5de4-4f87-8384-22f50675ea72>

Outro benchmark que mede a capacidade de usar skills: (Cho et al. 2026)

Trazer alguns resultados já divulgados.

Mostrar que não tem benchmark como o nosso que represente informação 2D como texto (fácil para o humano entender) e que seja agêntico de longo prazo (O mais próximo é o BALROG)

3 Method

Explicar como é o benchmark proposto Código de um agente ReAct - fixo Prompts fixos - fixos (inglês) Adaptação dos ambientes MiniGrid retornar observações textuais puramente onde o mapa 2D é representado em múltiplas linhas de texto Variações informação global vs local representação do mapa Explica como são os testes (centenas/milhares de execuções) rodar X vezes em tal ambiente rodar Y vezes em tal ambiente ... Métrica final no final, retorna o percentual de ambientes resolvidos

3.1 Experimental Setup

Descrição dos experimentos.

4.1 Modelos top de diferentes providers

4.2 Modelos de diferentes tamanhos, de uma mesma família

4.3 Modelos de mesmo tamanho, de diferentes famílias

4 Results

Apresentação dos resultados.

5 Discussion

Discussão dos resultados.

6 Conclusion

Muito brevemente, lembrar: o que foi proposto e os resultados que obtive

Esperada: ele é um bom benchmark agêntico, capaz de diferenciar modelos mais capazes dos menos capazes.

Trabalhos futuros.

7 Acknowledgments

8 References

- Acharya, Deepak Bhaskar, Karthigeyan Kuppan, and B Divya. 2025. “Agentic AI: Autonomous Intelligence for Complex Goals—a Comprehensive Survey.” *IEEE Access* 13: 18912–36.
- Achiam, Josh, Steven Adler, Sandhini Agarwal, et al. 2023. “Gpt-4 Technical Report.” *arXiv Preprint arXiv:2303.08774*.
- Chan, Jun Shern, Neil Chowdhury, Oliver Jaffe, et al. 2025. “Mle-Bench: Evaluating Machine Learning Agents on Machine Learning Engineering.” *International Conference on Learning Representations* 2025: 50466–94.
- Chen, Mark, Jerry Tworek, Heewoo Jun, et al. 2021. “Evaluating Large Language Models Trained on Code.” *arXiv Preprint arXiv:2107.03374*.
- Cho, Hongcheol, Ryangkyung Kang, and Youngeun Kim. 2026. “SkillRet: A Large-Scale Benchmark for Skill Retrieval in LLM Agents.” *arXiv Preprint arXiv:2605.05726*.
- Cobbe, Karl, Vineet Kosaraju, Mohammad Bavarian, et al. 2021. “Training Verifiers to Solve Math Word Problems.” *arXiv Preprint arXiv:2110.14168*.
- Hendrycks, Dan, Collin Burns, Steven Basart, et al. 2020. “Measuring Massive Multitask Language Understanding.” *arXiv Preprint arXiv:2009.03300*.
- Liu, Yujian, Jiabao Ji, Li An, Tommi Jaakkola, Yang Zhang, and Shiyu Chang. 2026. “How Well Do Agentic Skills Work in the Wild: Benchmarking Llm Skill Usage in Realistic Settings.” *arXiv Preprint arXiv:2604.04323*.
- Lu, Chris, Cong Lu, Robert Tjarko Lange, et al. 2026. “Towards End-to-End Automation of AI Research.” *Nature* 651 (8107): 914–19.

- McIntosh, Timothy R, Teo Susnjak, Nalin Arachchilage, et al. 2025. “Inadequacies of Large Language Model Benchmarks in the Era of Generative Artificial Intelligence.” *IEEE Transactions on Artificial Intelligence* 7 (1): 22–39.
- Paglieri, Davide, Bartłomiej Cupiał, Samuel Coward, et al. 2025. “Balrog: Benchmarking Agentic Llm and Vlm Reasoning on Games.” *International Conference on Learning Representations* 2025: 96666–702.
- Russell, Stuart Jonathan, Peter Norvig, John F Canny, Jitendra M Malik, and Douglas D Edwards. 1995. *Artificial Intelligence: A Modern Approach*. Vol. 2. Prentice hall Englewood Cliffs, NJ.
- Shoham, Yoav, and Kevin Leyton-Brown. 2009. *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Cambridge University Press. <https://www.masfoundations.org/>.
- Team, Gemma, Sherif El Abd, Vaibhav Aggarwal, et al. 2026. “Gemma 4 Technical Report.” *arXiv Preprint arXiv:2607.02770*.
- Wang, Alex, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel R Bowman. 2018. “GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding.” *Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP*, 353–55.
- Xi, Zhiheng, Wenxiang Chen, Xin Guo, et al. 2025. “The Rise and Potential of Large Language Model Based Agents: A Survey.” *Science China Information Sciences* 68 (2): 121101.
- Zhao, Wayne Xin, Kun Zhou, Junyi Li, et al. 2026. “A Survey of Large Language Models.” *Frontiers of Computer Science* 20 (12): 2012627.